

Ứng dụng Học máy Giải thích trong Dự đoán Gen Kháng Kháng sinh từ Dữ liệu Hệ gen Vi khuẩn

La Gia Hân[†] Nguyễn Phương Nguyên[†] Nguyễn Thị Phương Tuyền[†] Võ Thụy Sao Mai[†]

[†]Trường Đại học Công nghệ Thông tin – ĐHQG-HCM
{24520448, 24521196, 24521961, 24521038}@gm.uit.edu.vn

Môn học: Tư duy tính toán cho Khoa học Dữ liệu – DS107

Tóm tắt nội dung

Kháng kháng sinh (AMR) là một thách thức lớn trong y tế hiện đại, đặc biệt với *Escherichia coli*. Nghiên cứu này xây dựng pipeline học máy dự đoán kháng Ciprofloxacin từ dữ liệu giải trình tự toàn bộ hệ gen (WGS). Dữ liệu được biểu diễn qua hai nhóm đặc trưng bổ trợ: 210 gen kháng thuốc từ AMRfinderPlus và 100 Protein 3-mers (chọn lọc bằng Random Forest Importance), tạo ma trận 2404×310 . Bốn mô hình (XGBoost, Random Forest, LightGBM, Stacking Ensemble) được tối ưu bằng Optuna và đánh giá qua Stratified 5-Fold CV. XGBoost Pipeline được chọn nhờ objective cao nhất, đạt Accuracy 0.81, Macro-F1 0.81, ROC-AUC 0.9009, PR-AUC 0.8880 với ngưỡng tối ưu 0.479, ưu tiên phát hiện lớp kháng thuốc. Ba đột biến `parC_S80I`, `gyrA_D87N`, `gyrA_S83L` có tương quan mạnh nhất với tính kháng ($r \approx 0.43, 0.42, 0.34$). Phân tích SHAP xác nhận vai trò của chúng và phát hiện đóng góp phi tuyến của Protein 3-mers. Hệ thống được triển khai dưới dạng Web App (Flask) với báo cáo chẩn đoán tự động. Kết quả cần được kiểm chứng trên dữ liệu độc lập trước khi ứng dụng lâm sàng.

1 Giới thiệu

1.1 Bối cảnh và động lực

AMR hiện được WHO xếp vào 10 mối đe dọa sức khỏe toàn cầu hàng đầu [1]. Đặc biệt, vi khuẩn *Escherichia coli* là tác nhân gây bệnh hàng đầu trong các trường hợp nhiễm trùng huyết và nhiễm trùng đường tiết niệu. Ciprofloxacin (nhóm kháng sinh Fluoroquinolone) là lựa chọn điều trị phổ biến nhưng tỷ lệ kháng thuốc tăng nhanh. Phương pháp vi sinh truyền thống (nuôi cấy, kháng sinh đồ AST) mất 24 đến 72 giờ. Đây là khoảng thời gian quá dài với bệnh nhân nguy kịch.

Trong bối cảnh đó, dữ liệu giải trình tự toàn bộ hệ gen WGS (Whole Genome Sequencing) ngày càng trở nên phổ biến nhờ chi phí tối ưu, mở ra cơ hội ứng dụng khoa học dữ liệu và học máy để dự đoán nhanh tính kháng thuốc, từ đó hỗ trợ ra quyết định lâm sàng kịp thời và chính xác hơn [2].

Tuy nhiên, xây dựng mô hình từ WGS đặt ra ba câu hỏi tính toán cốt lõi: (1) *Biểu diễn*: chuyển chuỗi DNA thô (~50 GB) thành vector; (2) *Mô hình hóa*: tối ưu với dữ liệu thưa, đa cộng tuyến và mất cân bằng lớp; (3) *Giải thích*: kiểm chứng kết quả bằng tri thức sinh học để xây dựng niềm tin lâm sàng.

1.2 Thách thức

Mặc dù tiềm năng là lớn, việc xây dựng các mô hình học máy từ dữ liệu WGS đối mặt với nhiều thách thức:

Lời nguyền đa chiều (Curse of Dimensionality): Không gian k-mer lý thuyết là $20^3 = 8000$ triplet; thực tế quan sát ~10.695 k-mer duy nhất trên 5.027 genome. Nếu đưa toàn bộ vào mô hình, nguy cơ overfitting rất cao so với 2.404 mẫu cuối cùng. Điều này đặt ra yêu cầu *phân rã*: tách bài toán lựa chọn đặc trưng thành bài toán con riêng, giải quyết trước khi huấn luyện.

Tính thưa và đa cộng tuyến: Dữ liệu gen có cấu trúc thưa, với khoảng 69.8% giá trị bằng 0. Ngoài ra, các đột biến kháng thuốc thường xuất hiện đồng thời thành từng “cụm di truyền”, tạo ra hiện tượng đa cộng tuyến nghiêm trọng (127 cặp đặc trưng có tương quan $|r| > 0.95$). Đây là *mẫu hình* quan trọng: nó vừa gợi ý mô hình phi tuyến là phù hợp (thay vì tuyến tính), vừa cảnh báo rằng tương quan đơn thuần không đủ để chọn đặc trưng.

Tính diễn giải: Các mô hình học máy phức tạp như XGBoost hay Random Forest thường hoạt động như một “hộp đen”. Trong lĩnh vực y sinh, khả năng

giải thích tại sao một mẫu được dự đoán là kháng thuốc là yếu tố quan trọng không kém độ chính xác. Đó là cơ sở để các bác sĩ thiết lập niềm tin và ứng dụng công nghệ vào thực tế.

1.3 Đóng góp chính

Để giải quyết các thách thức trên, nghiên cứu này đóng góp:

1. **Quy trình trích xuất đặc trưng đa nguồn (Hybrid Feature Engineering Pipeline):** Kết hợp 210 đặc trưng AMR genes (tri thức chuyên gia) và 100 Protein 3-mers được chọn lọc bằng Random Forest Importance, tạo ma trận 2.404×310 .
2. **Hàm mục tiêu có ràng buộc cho Optuna:** Xây dựng hàm Optuna ưu tiên macro-F1 nhưng phạt khi recall Resistant < 0.80 , phản ánh chi phí bất cân xứng giữa 2 loại lỗi phân loại False Negative và False Positive trong y tế.
3. **Pipeline kiểm soát rò rỉ thông tin:** SMOTE và RFE được đặt bên trong pipeline, chỉ áp dụng trên phần huấn luyện của từng fold CV.
4. **Xác nhận dấu ấn sinh học và phát hiện tín hiệu mới:** Phát hiện bộ ba đột biến vàng (parC_S80I, gyrA_D87N, gyrA_S83L) và vai trò tiềm năng của Protein 3-mers (gpc, ycq) trong cơ chế kháng thuốc phi tuyến, mở ra hướng nghiên cứu cơ chế kháng thuốc mới.
5. **Khả năng diễn giải (Explainable AI – XAI) và triển khai thực tế:** Tích hợp SHAP để giải thích dự đoán; hệ thống được triển khai dưới dạng Web App (Flask) với báo cáo lâm sàng tự động qua API Gemini.

2 Các nghiên cứu liên quan

2.1 Dự đoán kháng kháng sinh từ WGS trên quy mô lớn

Stoesser và cộng sự [3] đã sử dụng XGBoost trên 1.862 mẫu *E. coli* để dự đoán tính kháng Ciprofloxacin, đạt AUC 0.94. Tương tự, Nguyen và cộng sự [4] áp dụng Random Forest trên 500 mẫu *Klebsiella pneumoniae*, nhấn mạnh vai trò của các đột biến điểm trên gen *gyrA* và *parC*. Các nghiên cứu này chứng minh hiệu quả của học máy nhưng chỉ dừng đặc trưng chuyên gia (AMR genes), bỏ qua các cơ chế kháng thuốc chưa được định danh.

2.2 Phương pháp đặc trưng không dựa trên tham chiếu (Reference-free)

Kỹ thuật đếm K-mer trên DNA được sử dụng rộng rãi để phát hiện các cấu trúc gen lạ [5]. Tuy nhiên, phương pháp này nhạy cảm với các đột biến silent (silent mutations) không làm thay đổi axit amin. Camacho và cộng sự [6] đề xuất sử dụng Protein K-mer để khắc phục nhược điểm này, vì Protein phản ánh chuỗi axit amin sau phiên mã, các đột biến câm không tạo ra thay đổi ở cấp protein, nên tín hiệu k-mer protein ổn định hơn.

2.3 Khoảng trống nghiên cứu

Mặc dù các nghiên cứu trước đạt độ chính xác dự đoán cao (AUC lên đến 0.94), nhưng chưa có công trình nào xây dựng một pipeline hoàn chỉnh kết hợp đồng thời ba yếu tố: (1) pipeline đặc trưng lai giữa AMR genes và Protein 3-mers, (2) hàm mục tiêu có ràng buộc recall, và (3) khả năng diễn giải mô hình bằng SHAP tích hợp Web App lâm sàng cho bài toán dự đoán kháng Ciprofloxacin trên *E. coli*. Chính vì vậy, nghiên cứu này hướng tới mục tiêu khắc phục khoảng trống kỹ thuật nói trên bằng việc phát triển một hệ thống chẩn đoán kháng thuốc thông minh, tối ưu về mặt hiệu năng và minh bạch về mặt cơ chế y khoa.

3 Tiền xử lý dữ liệu

3.1 Nguồn dữ liệu thô

Dữ liệu sử dụng trong nghiên cứu này được thu thập từ cơ sở dữ liệu BV-BRC (Bacterial and Viral Bioinformatics Resource Center) [7], bao gồm hai thành phần:

- **Genomic data:** 7.334 file FASTA, mỗi file chứa một genome *E. coli* hoàn chỉnh (50–200 contigs, khoảng 8 GB tổng dung lượng).
- **Metadata:** File BVBRC_genome_amr.csv (8.635 dòng, 7.334 Genome ID duy nhất) chứa kết quả kháng sinh đồ (Phenotype) cho nhiều loại kháng sinh, bao gồm thông tin về tính kháng (Resistant), nhạy cảm (Susceptible), hoặc trung gian (Intermediate) đối với nhiều loại kháng sinh, trong đó chỉ sử dụng nhãn Ciprofloxacin.

3.2 Vấn đề biểu diễn: từ chuỗi DNA đến vector

Bước đầu tiên trong tư duy tính toán là *trừu tượng hóa*: làm thế nào để chuyển một genome ~5MB DNA

thành một vector số mà máy tính có thể học được? Cụ thể, cần trả lời ba câu hỏi:

Bao nhiêu chiều? — Không quá lớn để tránh overfitting, cũng không quá nhỏ để mất thông tin.

Mã hóa điều gì? — Loại thông tin nào phản ánh đúng cơ chế kháng thuốc?

Bỏ qua điều gì? — Yếu tố nào là nhiễu hoặc không liên quan?

Để trả lời, nhóm phân rã bài toán thành hai nguồn thông tin bổ trợ cho nhau:

- **Nguồn (a) — Tri thức chuyên gia:** Sự hiện diện của các gen kháng thuốc *đã biết*. Ưu điểm: xác định, dễ diễn giải sinh học. Hạn chế: bỏ qua cơ chế kháng thuốc *chưa được phát hiện*.
- **Nguồn (b) — Tín hiệu từ dữ liệu:** Tần suất các đoạn protein ngắn (k-mer). Ưu điểm: có thể phát hiện mẫu hình mới, kể cả khi chưa biết cơ chế. Hạn chế: khó diễn giải hơn.

Quyết định thiết kế: **kết hợp cả hai nguồn**. Không nguồn nào đủ mạnh một mình. AMR genes quá hẹp (chỉ thấy cái đã biết), k-mer quá mờ (thiếu ý nghĩa sinh học). Kết hợp chúng tạo ra một biểu diễn *vừa có thể giải thích, vừa có thể khám phá* — phù hợp với bài toán y sinh, nơi tri thức cũ và dữ liệu mới đều quan trọng.

3.3 Làm sạch và lọc dữ liệu

Quy trình làm sạch được thực hiện qua 3 bước tương ứng, kết quả từng bước trình bày trong Bảng 1.

Lọc FASTA: Đối chiếu Genome ID giữa FASTA và metadata, giữ lại 5.027 genome có đủ cả chuỗi gen và nhãn lâm sàng.

Làm sạch nhãn: Lọc theo kháng sinh Ciprofloxacin, loại bỏ nhãn *Intermediate* (vùng xám sinh học), mã hóa Resistant $\rightarrow 1$, Susceptible $\rightarrow 0$. Nếu một genome có nhiều entries, lấy `label.max()` để ưu tiên nhãn Resistant.

Intersection: Sau khi trích xuất song song X_{AMR} và X_{kmer} , chỉ giữ các genome xuất hiện đồng thời trong cả ba nguồn (AMR matrix, k-mer matrix, label file), thu được **2.404 genomes** cuối cùng.

Bảng 1: Thống kê dữ liệu qua từng bước làm sạch

Bước	Mô tả	Mẫu
0	FASTA ban đầu (BV-BRC)	7.334
1	Lọc FASTA có trong metadata	5.027
2	Lọc Cipro + loại Intermediate	5.027
3	Intersection gene+k-mer+label	2.404

Quyết định thiết kế – loại nhãn Intermediate: Nhãn Intermediate đại diện cho “vùng xám sinh học”

– các chủng không phân loại được rõ ràng bằng phương pháp AST. Giữ lại chúng sẽ làm mờ ranh giới phân loại và giảm chất lượng tín hiệu học. Đây là bước trừu tượng hóa có chủ ý: chấp nhận mất một số mẫu để đổi lấy nhãn rõ ràng hơn.

Quyết định thiết kế – tách X và y : Nhãn mục tiêu được lưu riêng trong `y.csv` (không nhúng vào ma trận đặc trưng). Việc ghép nối theo Genome ID là bước bắt buộc trước huấn luyện, nếu bỏ qua bước này sẽ dẫn đến mã tự động nhầm cột cuối của ma trận (ví dụ `rpm`, một biến đếm Protein 3-mer) làm nhãn mục tiêu, sai lệch hoàn toàn kết quả.

3.4 Kiểm tra tính toàn vẹn

Sau bước Intersection, ma trận 2404×310 được xác minh: không có NaN, các cột AMR là binary $\in \{0, 1\}$, các cột k-mer là số nguyên ≥ 0 (raw count, chưa chuẩn hóa – StandardScaler áp dụng ở bước huấn luyện).

4 Phân tích khám phá dữ liệu

4.1 Thống kê tổng quan dữ liệu

Tập dữ liệu sau khi xử lý đầy đủ (đã ghép nối đặc trưng với nhãn lại) có các đặc trưng thống kê được trình bày trong Bảng 2.

Bảng 2: Thống kê tổng quan và hàm ý thiết kế

Đặc tính	Giá trị	Hàm ý
Số mẫu (N)	2.404	Đủ cho K-Fold
Đặc trưng ban đầu	>8K	Cần lọc k-mer
Sau lọc RF	310	210+100
Sparsity	69.8%	Mô hình cây
Đa cộng tuyến	127 c.	$ r > 0.95$

4.2 Phân phối nhãn và cân bằng lớp


Trên 2.404 mẫu: Susceptible (0) chiếm 59.19% (1.423 mẫu), Resistant (1) chiếm 40.81% (981 mẫu). Đây không phải mất cân bằng nghiêm trọng về mặt thống kê, nhưng vấn đề then chốt nằm ở *tác động bất đối xứng* của sai lầm chẩn đoán: một False Negative (dự đoán nhạy cảm trong khi thực tế kháng thuốc) có thể khiến bệnh nhân thất bại điều trị, trong khi False Positive (dự đoán kháng nhưng thực tế nhạy) chỉ dẫn đến thay đổi kháng sinh dự phòng. Hậu quả của FN lớn hơn rõ rệt. Do đó, nhóm tuyên bố recall của lớp Resistant là chỉ số ưu tiên hàng đầu trong thiết kế hàm mục tiêu.

4.3 Đa cộng tuyến (Multicollinearity Analysis)

Phân tích ma trận tương quan giữa các đặc trưng phát hiện 127 cặp đặc trưng có $|r| > 0.95$, ví dụ điển hình là *gyrA_D87N* và *gyrA_S83L*. Đây không phải nhiễu mà là *mẫu hình sinh học có nghĩa*: các đột biến trong cùng vùng QRDR (Quinolone Resistance Determining Region) [8] thường xuất hiện đồng thời do di truyền liên kết hoặc hiệu ứng hiệp đồng. Nhận diện mẫu hình này dẫn đến hai hệ quả thiết kế: (a) mô hình tuyến tính thuần sẽ không ổn định, cần regularization; (b) mô hình dạng cây ít bị ảnh hưởng hơn, nhưng vẫn cần kiểm soát overfitting.

4.4 Phân tích đặc trưng sơ bộ

Sử dụng hệ số tương quan điểm (point-biserial correlation) giữa từng đặc trưng với biến mục tiêu nhị phân (Xem hình 1), nhóm xác định được các đặc trưng có mối quan hệ tuyến tính mạnh nhất (Bảng 3).



Hình 1: Hệ số tương quan điểm của Top 10 đặc trưng


Bảng 3: Top đặc trưng tương quan mạnh nhất với biến mục tiêu (tính trên $N = 2.404$ mẫu)

Hạng	Đặc trưng	Hệ số tương quan $ r $
1	parC_S80I	≈ 0.43
2	gyrA_D87N	≈ 0.42
3	gyrA_S83L	≈ 0.34

Nhận xét quan trọng: Các đặc trưng Protein 3-mers (như *gpc*, *ycq*) không xuất hiện trong top tương quan tuyến tính. Tuy nhiên, điều này không đồng nghĩa với việc chúng không mang giá trị dự báo, ảnh hưởng của chúng lên tính kháng thuốc có thể là phi tuyến tính hoặc thông qua các mối tương tác phức tạp với các gen khác. Đây là cơ sở luận điểm then chốt cho việc lựa chọn các mô hình dạng cây như XGBoost hay Random Forest.

5 Feature Engineering

Nhóm xây dựng quy trình trích xuất đặc trưng đa nguồn gồm hai nhánh chính, kết hợp kiến thức chuyên gia và khả năng khám phá của AI. Sơ đồ tổng quan được mô tả trong Hình 2.



Hình 2: Pipeline feature engineering

5.1 Nhánh 1: Đặc trưng chuyên gia từ gen kháng thuốc (X_{AMR})

Mục đích: Mã hóa sự hiện diện của các cơ chế kháng thuốc đã biết, đảm bảo khả năng diễn giải sinh học.

Lý do chọn AMRFinderPlus: Đây là tool chuẩn của NCBI, tích hợp database CARD + ARDB + custom HMMs, phát hiện cả gene presence lẫn point mutations. Tham số *-O* *Escherichia* tối ưu hóa cho *E. coli* [9].

Lọc gen hiếm: Từ $\sim 400+$ gen ban đầu, chỉ giữ gen xuất hiện trong $\geq 1\%$ tổng số genome (prevalence filter), còn lại 210 gen. Lý do: gen quá hiếm không đóng góp tín hiệu phân loại nhất quán, nhưng lại làm tăng chiều dữ liệu.

Đầu ra: Ma trận nhị phân 2404×210 (1: có gen/đột biến, 0: không). Các đặc trưng tiêu: *parC_S80I*, *gyrA_D87N*, *gyrA_S83L*, *blaCTX-M-15*, *sul1*, *tet(A)*.

Chiến lược chuẩn hóa: StandardScaler được áp dụng thống nhất cho toàn bộ ma trận $X_{combined}$ (310 cột) ở bước huấn luyện. Riêng với SHAP, giá trị AMR gốc (0/1) vẫn được giữ nguyên để đảm bảo tính diễn giải sinh học.

5.2 Nhánh 2: Đặc trưng cấu trúc từ Protein 3-mers (X_{kmer})

Mục đích: Phát hiện cấu trúc gen lạ, vùng điều hòa, cơ chế kháng thuốc chưa biết theo phương pháp không đối chiếu tham chiếu (reference-free).

Lý do chọn Protein thay vì DNA: DNA k-mer nhạy cảm với đột biến câm – những thay đổi nucleotide không làm thay đổi axit amin. Protein

3-mer phản ánh chức năng sinh học thực sự. Đây là quyết định trừu tượng hóa có chủ ý: bỏ qua thông tin chuỗi DNA, chỉ giữ thông tin chuỗi protein.

Quy trình: DNA được dịch mã thành protein bằng Prodigal [10], sau đó trích xuất tần suất các triplet ($k = 3$) trên toàn bộ chuỗi protein. Các k-mer hiếm (xuất hiện trong $< 0.1\%$ genome) bị loại, và 100 k-mer quan trọng nhất được chọn bằng Random Forest Importance.

Đầu ra: kết quả là ma trận tần suất 2404×100 , giá trị là số nguyên đếm tần suất (raw count, ≥ 0).

5.3 Hợp nhất và chọn lọc đặc trưng cuối cùng

Ghép nối hai ma trận: X_{AMR} (210) và X_{kmer} (100) thu được 310 đặc trưng.

Lọc Random Forest Importance: chọn ra 100 k-mer có điểm importance cao nhất (đã thực hiện ở bước trích xuất k-mer).

Ghép nhãn: Merge với cột **Resistant** từ **y.csv** theo Genome ID.

Kết quả: **310 đặc trưng** trên **2.404 mẫu** (59.19% Susceptible, 40.81% Resistant).

5.4 So sánh phương pháp Feature Selection

Ba phương pháp đã được thử nghiệm trên cùng tập 5.027 genomes để chọn 100 k-mer tốt nhất. Kết quả trình bày trong Bảng 4.

Bảng 4: So sánh phương pháp chọn 100 Protein 3-mer

PP	AUC	Rec.	Prec.	F1
Chi-Square	0.9096	80.6%	79.0%	79.8%
ANOVA F-test	0.9054	82.1%	78.5%	80.3%
RF Importance	0.9133	81.6%	80.8%	81.2%

RF Importance được chọn vì đạt ROC-AUC và F1 cao nhất, đồng thời phù hợp với bản chất phi tuyến của dữ liệu gen. Chi-Square giả định độc lập giữa các đặc trưng, giả định này bị vi phạm khi có đa cộng tuyến; ANOVA F-test chỉ đo quan hệ tuyến tính [11]. RF Importance không bị giới hạn bởi hai giả định này.

Kết quả cuối cùng là ma trận đặc trưng 2404×310 , bao gồm 210 đặc trưng Boolean từ AMR genes và 100 đặc trưng tần suất từ Protein 3-mers, cả hai đều được chuẩn hóa bằng StandardScaler.

5.5 Các tập dữ liệu đầu ra

Dữ liệu đầu ra được lưu gồm: X.csv (ma trận X đặc trưng) có kích thước (2404×310) , y.csv (nhãn) có kích

thước 2404×2 , scaler.pkl, và top_100_kmers.csv (danh sách 100 k-mer được chọn) có kích thước 100×2 .

6 Chiến lược xây dựng mô hình

6.1 Mục tiêu huấn luyện và tiêu chí đánh giá

Trước khi lựa chọn mô hình, nhóm xác định lại bản chất của bài toán dưới góc nhìn tư duy tính toán: đây không chỉ là bài toán phân loại nhị phân, mà còn là bài toán ra quyết định có chi phí sai lầm không đối xứng. Trong bối cảnh kháng kháng sinh, lỗi False Negative, tức dự đoán một chủng kháng thuốc thành nhạy cảm, nguy hiểm hơn False Positive vì có thể dẫn đến việc tiếp tục sử dụng Ciprofloxacin không hiệu quả.

Vì vậy, nhóm không tối ưu đơn thuần theo Accuracy, mà ưu tiên Recall của lớp Resistant, đồng thời vẫn duy trì Macro-F1 để đảm bảo hiệu năng cân bằng giữa hai lớp. Yêu cầu thực tiễn này được chuyển thành hàm mục tiêu có penalty trong Optuna:

$$\text{objective} = \text{macro-F1} \times \max(0, 0.80 - \text{recallR}) \times 0.5$$

Cách thiết kế này thể hiện bước chuyển từ yêu cầu miền y sinh sang tiêu chí tối ưu cụ thể cho mô hình học máy: mô hình được khuyến khích phát hiện tốt mẫu kháng thuốc, nhưng vẫn bị đánh giá trên hiệu năng tổng thể.

6.2 Quy trình huấn luyện cho từng mô hình


Để đánh giá mô hình một cách ổn định, dữ liệu được chia thành 85% train và 15% test bằng stratified split nhằm giữ nguyên tỷ lệ giữa hai lớp Susceptible và Resistant. Tập test được giữ riêng trong suốt quá trình tối ưu để đóng vai trò đánh giá cuối cùng.

Trên tập train, nhóm sử dụng Stratified 5-Fold Cross-Validation. Đây là lựa chọn phù hợp với dữ liệu có phân bố lớp không hoàn toàn cân bằng, vì mỗi fold vẫn giữ được tỷ lệ lớp tương đối ổn định. Nhờ đó, kết quả đánh giá không phụ thuộc vào một lần chia dữ liệu ngẫu nhiên duy nhất.

Để đảm bảo so sánh công bằng và kiểm soát rò rỉ thông tin, mỗi mô hình có cùng cấu trúc pipeline như hình 3

Lý do đặt SMOTE bên trong pipeline: Nếu SMOTE áp dụng trước CV, các mẫu nhân tạo từ tập validation sẽ rò rỉ vào tập train – vi phạm nguyên tắc đánh giá độc lập. Đặt SMOTE trong pipeline đảm bảo nó chỉ thấy phần train của từng fold.

VarianceThreshold (ngưỡng 0.01): Loại đặc trưng gần như hằng số trên toàn tập. Kết quả: 310



Hình 3: Pipeline huấn luyện

đặc trưng giảm xuống còn 146 sau bước này – cho thấy gần một nửa đặc trưng AMR có phương sai rất thấp (gen hiếm chỉ xuất hiện ở rất ít genome).

RFE: Số đặc trưng giữ lại ($k_features$) được tối ưu bởi Optuna, không cố định trước. Điều này cho phép mỗi mô hình tìm số đặc trưng tối ưu cho bản thân, thay vì dùng chung một con số.

6.3 Lựa chọn mô hình nền

Cả ba mô hình đều thuộc họ cây quyết định, phù hợp với đặc điểm dữ liệu: thưa, phi tuyến, đa cộng tuyến cao. Sự lựa chọn không phải ngẫu nhiên mà xuất phát từ sự đa dạng về chiến lược học: (1) **Random Forest (bagging):** Xây nhiều cây độc lập, tổng hợp kết quả. Ổn định, ít overfitting, nhưng mỗi cây học độc lập nên có thể bỏ lỡ tương tác phức tạp. (2) **XGBoost (gradient boosting):** Các cây học tuần tự, mỗi cây sửa lỗi của cây trước. Mạnh hơn với dữ liệu có nhiều tương tác phi tuyến, nhưng dễ overfit nếu không regularize. (3) **LightGBM (gradient boosting, leaf-wise):** Cơ chế xây cây khác XGBoost (leaf-wise thay vì level-wise), thường nhanh hơn và đôi khi tốt hơn trên dữ liệu thưa.

Sự đa dạng này tạo nền tảng cho stacking: ba mô hình có thể mắc lỗi ở các mẫu khác nhau, và meta-learner học cách bù đắp.

6.4 Tối ưu siêu tham số và kiểm soát overfitting

Optuna tìm kiếm tự động qua 50 trials mỗi mô hình, dùng TPE Sampler [12]. Không gian tìm kiếm bao gồm cả tham số mô hình lẫn tham số pipeline:

- $smote_strategy \in [0.58, 1.0]$: mức cân bằng lớp
- $k_features \in [10, 100]$: số đặc trưng giữ sau RFE
- Tham số mô hình cụ thể (learning rate, depth, regularization, v.v.)

Hàm mục tiêu được định nghĩa ở 6.1

Bên cạnh việc tối ưu siêu tham số, nhóm sử dụng nhiều cơ chế để kiểm soát overfitting trong toàn bộ pipeline. *VarianceThreshold* loại bỏ các đặc trưng gần

như không biến thiên, RFE giới hạn số lượng đặc trưng được đưa vào mô hình, SMOTE được đặt bên trong pipeline để chỉ cân bằng dữ liệu trong từng phần huấn luyện của cross-validation, còn các tham số điều chuẩn và giới hạn cấu trúc cây được tối ưu bằng Optuna. Nhờ đó, mô hình được lựa chọn không dựa trên một cấu hình thủ công, mà dựa trên quá trình thử nghiệm có kiểm soát và đánh giá lặp lại bằng cross-validation.

6.5 Stacking ensemble và lựa chọn mô hình cuối

Theo hàm mục tiêu đã định (ưu tiên macro-F1, phạt khi recall < 0.80 trên tập validation), nhóm chọn XGBoost Pipeline làm mô hình cuối. Trên tập test, recall của XGBoost đạt 0.77 — thấp hơn mục tiêu 0.80. Tuy nhiên, nhóm vẫn giữ XGBoost vì:

- **Stacking có recall cao hơn** (0.82) nhưng **macro-F1 thấp hơn** (83.56% so với 84.84%), cho thấy nó hoạt động kém cân bằng hơn giữa hai lớp.
- **Việc recall trên test thấp hơn mục tiêu** phản ánh sự phân kỳ tự nhiên giữa train và test, không phải do lựa chọn mô hình sai. Cả hai mô hình đều bị ảnh hưởng tương tự.
- **XGBoost được ưu tiên** vì nó vượt trội về macro-F1 — chỉ tiêu tổng hợp phản ánh chất lượng toàn diện, đặc biệt quan trọng trong bối cảnh dữ liệu mất cân bằng và chi phí sai lệch bất đối xứng.

6.6 Tối ưu ngưỡng quyết định

Ngưỡng mặc định 0.5 không phải lựa chọn tốt nhất khi có mất cân bằng lớp và ràng buộc recall. Nhóm thực hiện nested threshold tuning: (1) Chia X_{train} thành 5 fold inner CV. (2) Tại mỗi fold: fit mô hình trên 4 phần, dự đoán xác suất trên phần còn lại. (3) Quét ngưỡng $\in [0.30, 0.71]$ với bước 0.001: chọn ngưỡng có macro-F1 cao nhất trong số các ngưỡng đạt recall Resistant ≥ 0.80 . (4) Ngưỡng cuối = trung vị 5 fold: 0.479.

Kết quả từng fold: 0.401, 0.510, 0.479, 0.513, 0.479 → trung vị 0.479. Dùng trung vị thay vì trung bình để tránh ảnh hưởng của các fold ngoại lai.

7 Kết quả

7.1 Kết quả EDA và phân tích đặc trưng

Trên tập dữ liệu 2.404×310 , phân tích tương quan điểm (point-biserial correlation) giữa từng đặc trưng và biến mục tiêu nhị phân xác nhận bộ ba đột biến vàng với hệ số tương quan cao nhất (Bảng 3). Đáng chú ý, các đoạn Protein 3-mers như **gpc** và **ycq** xuất hiện trong Top 10 đặc trưng quan trọng nhất theo Random Forest Importance (Hình 1), cho thấy tín hiệu phi tuyến mạnh mà tương quan tuyến tính chưa nắm bắt được.

7.2 Kết quả huấn luyện và đánh giá mô hình

Toàn bộ pipeline huấn luyện được thực thi qua `run_training.py`, bao gồm 3 giai đoạn: (1) tối ưu hóa riêng từng base learner bằng Optuna (50 trials mỗi mô hình), (2) huấn luyện Stacking Ensemble, và (3) tìm ngưỡng quyết định tối ưu theo F1-score Resistant.

Bảng 5: So sánh CV (Stratified 5-Fold, trên X_{train})

Mô hình	Macro-F1	Recall(R)	Obj.
XGBoost	84.84%	79.85%	0.8477
Random Forest	82.93%	75.66%	0.8076
LightGBM	84.16%	79.74%	0.8403
Stacking	83.56%	81.89%	0.8356

Nhận xét: Stacking đạt recall Resistant cao nhất (81.89%) nhưng objective thấp hơn XGBoost do macro-F1 thấp hơn. Nếu ưu tiên tuyệt đối recall thay vì cân bằng, Stacking là lựa chọn thay thế hợp lý. Nhóm chọn XGBoost theo tiêu chí objective đã đặt ra.

Mô hình cuối (XGBoost Pipeline, ngưỡng 0.479) được đánh giá trên tập test (361 mẫu, 15% tổng) được tổng hợp trong Bảng 6. XGBoost Pipeline được chọn là mô hình cuối theo CV.

Bảng 6: Kết quả XGBoost Pipeline trên tập test (15%, 361 mẫu)

Chỉ số	Giá trị
Accuracy	0.81
Macro-F1	0.81
Recall (Resistant)	0.77
ROC-AUC	0.9009
PR-AUC	0.8880
Threshold	0.479

7.3 Giải thích mô hình bằng SHAP

Module `ml_pipeline.explain_prediction()` sử dụng `TreeExplainer` của SHAP để tính SHAP Values cho từng dự đoán. SHAP Summary Plot trên toàn tập Test cho thấy **parC_S80I** (giá trị = 1) đẩy xác suất kháng thuốc lên mạnh nhất, tiếp theo là **gyrA_D87N** và **gyrA_S83L**. Các đoạn 3-mer như **gpc** xuất hiện ở vị trí Top 5 theo SHAP importance, xác nhận đóng góp phi tuyến của chúng. Kết quả giải thích này được tích hợp trực tiếp vào Web App (Flask) thông qua `run_inference_example.py` để hiển thị báo cáo lâm sàng tự động cho từng mẫu vi khuẩn [13].

7.4 Triển khai Web App

Web App (Flask) hỗ trợ phân tích chủng đơn/hàng loạt, lưu lịch sử, giám sát dịch tễ, và sinh báo cáo lâm sàng tự động qua API Gemini.

8 Thảo luận

8.1 Xác nhận tri thức sinh học

Kết quả phân tích đặc trưng xác nhận hoàn toàn cơ chế kháng thuốc đã được y văn ghi nhận: **parC_S80I** và **gyrA_D87N/gyrA_S83L** là các đột biến tại vùng QRDR (Quinolone Resistance Determining Region) trực tiếp làm giảm ái lực gắn kết của Ciprofloxacin lên DNA gyrase và topoisomerase IV [9]. Việc mô hình tự học và xếp hạng ưu tiên đúng ba đột biến này mà không cần bất kỳ tiên nghiệm (prior) nào là bằng chứng mạnh cho tính đúng đắn của pipeline.

8.2 Giá trị của Protein 3-mer

Bước nâng cấp từ DNA k-mers sang Protein 3-mers mang lại lợi ích kép (điều mà AMR genes không có): (1) miễn nhiễm với các đột biến câm (silent mutations) không thay đổi axit amin, và (2) khả năng phát hiện cơ chế kháng thuốc chưa được định danh (ví dụ bơm đẩy thuốc – efflux pumps). Sự xuất hiện của **gpc**, **ycq** trong Top 10 đặc trưng SHAP là tín hiệu mở ra hướng nghiên cứu cơ chế kháng thuốc mới, đặc biệt có giá trị với các chủng kháng thuốc nhưng không mang đột biến điểm điển hình.

8.3 Phân tích chuyên sâu mô hình

Lưu ý: Các phân tích trong mục này (baseline, ablation, FN/FP) được thực hiện trên mô hình Stacking Ensemble với ngưỡng quyết định được tối ưu riêng trên tập validation (threshold = 0.523), khác với ngưỡng 0.479 của pipeline chính. Mục đích là đánh

giá hành vi mô hình ở ngưỡng có recall cao hơn, phục vụ phân tích lỗi.

Đánh giá baseline. So sánh ba cấu hình trên tập CV (Bảng 7) cho thấy Stacking Ensemble vượt trội hoàn toàn so với Dummy và Decision Tree, xác nhận mô hình thực sự học được pattern kháng thuốc.

Bảng 7: So sánh baseline trên tập CV (Stacking 5-Fold)

Chỉ số	Dummy	Simple DT	Stacking
Macro-F1	48.25%	77.82%	83.56%
Recall (R)	39.93%	55.63%	81.89%

Top đặc trưng quan trọng. Feature importance từ Random Forest trong stacking nhất quán với SHAP: *parC_S80I* (0.1432) và *gyrA_D87N* (0.1293) dẫn đầu, tiếp theo *gyrA_S83L* (0.0828). Đáng chú ý, Protein 3-mer *ycq* (0.0236) và *gpc* (0.0209) vào Top 6, xác nhận đóng góp phi tuyến của chúng.

Ablation study. Bảng 8 cho thấy SMOTE là thành phần đóng góp lớn nhất, RFE đơn lẻ không cải thiện nhưng kết hợp với SMOTE tạo pipeline ổn định.

Bảng 8: Ablation study (RF cố định, 5-Fold CV)

Cấu hình	Macro-F1	Recall
RF thuần	80.25%	62.47%
SMOTE only	82.23%	70.02%
RFE only	79.91%	61.15%
SMOTE + RFE	80.58%	64.63%

Phân tích lỗi FN/FP. Trên tập test (threshold 0.523, Bảng 9), FN rate 23.1% (34/147 ca kháng thuốc bị bỏ sót), FP rate 17.3% (37/214). Các mẫu FN là *borderline cases*: chủng kháng thuốc nhưng thiếu đột biến điển hình tại *parC/gyrA*. Trong y tế, FN nguy hiểm hơn FP — khuyến nghị kết hợp kết quả mô hình với kháng sinh đồ thực tế.

Bảng 9: Ma trận nhầm lẫn trên tập test (threshold = 0.523)

	Susc_predict	Res_predict
Susceptible thực	TN = 177	FP = 37
Resistant thực	FN = 34	TP = 113

8.4 Hạn chế

Nghiên cứu còn một số hạn chế cần lưu ý:

1. **Recall Resistant trên test (0.77) thấp hơn mục tiêu (0.80):** Threshold 0.479 được tối ưu trên train set. Khoảng cách 0.03 có thể thu hẹp bằng cách tăng số fold hoặc điều chỉnh hàm phạt.
2. **Thiếu kiểm chứng độc lập:** Toàn bộ 2.404 mẫu đến từ cùng cơ sở dữ liệu BV-BRC; cần đánh giá trên tập dữ liệu từ cơ sở y tế khác để khẳng định khả năng tổng quát hóa.
3. **Phụ thuộc vào chất lượng AMRFinderPlus:** Các gen kháng thuốc chưa được công bố sẽ không xuất hiện trong nhánh X_{AMR} ; Protein 3-mers đóng vai trò bù đắp quan trọng cho hạn chế này.

9 Kết luận

Nghiên cứu này đã trình bày một pipeline học máy toàn diện cho bài toán dự đoán tính kháng Ciprofloxacin ở *E. coli* từ dữ liệu WGS theo hướng tiếp cận tư duy tính toán theo 5 bước:

1. **Phân rã:** bài toán thành ba bài toán con: biểu diễn đặc trưng, tối ưu mô hình có ràng buộc, và giải thích kết quả.
2. **Nhận diện mẫu hình:** đa cộng tuyến là tín hiệu sinh học có nghĩa, recall quan trọng hơn accuracy trong bối cảnh lâm sàng, từ đó dẫn đến các quyết định thiết kế cụ thể.
3. **Trừu tượng hóa:** genome thành hai lớp đặc trưng bổ trợ nhau, bỏ qua những gì không cần thiết (thứ tự k-mer, đột biến câm).
4. **Tối ưu có ràng buộc:** qua hàm mục tiêu phản ánh chi phí bất cân xứng của hai loại lỗi lâm sàng.
5. **Đánh giá:** kết quả bằng SHAP không chỉ kiểm tra độ chính xác mà còn xác nhận mô hình học đúng cơ chế sinh học.

XGBoost Pipeline đạt Accuracy 0.81, Macro-F1 0.81, ROC-AUC 0.9009, PR-AUC 0.8880 trên tập test độc lập (threshold 0.479). Kết quả cần được kiểm chứng trên tập dữ liệu từ cơ sở y tế độc lập trước khi ứng dụng lâm sàng.

Phân tích SHAP xác nhận ba đột biến *parC_S80I*, *gyrA_D87N*, *gyrA_S83L* là tín hiệu mạnh nhất và phát hiện vai trò phi tuyến của Protein 3-mers (*gpc*, *ycq*), mở ra hướng nghiên cứu cơ chế kháng thuốc mới.

Lời cảm ơn

Nhóm cảm ơn sự hỗ trợ từ môn học DS107, Trường Đại học Công nghệ Thông tin – ĐHQG-HCM. Dữ liệu từ BV-BRC (Bacterial and Viral Bioinformatics Resource Center).

Tài liệu

- [1] Pugazhenthana Thangaraju and Sajitha Venkatesan. Who ten threats to global health in 2019: Antimicrobial resistance. *Cukurova Medical Journal*, 44(3):1150–1151, 2019.
- [2] Carlos M Ardila, Pradeep K Yadalam, and Daniel González-Arroyave. Integrating whole genome sequencing and machine learning for predicting antimicrobial resistance in critical pathogens: a systematic review of antimicrobial susceptibility tests. *PeerJ*, 12:e18213, 2024.
- [3] N Stoesser, EM Batty, DW Eyre, M Morgan, DH Wyllie, C Del Ojo Elias, James R Johnson, AS Walker, TEA Peto, and DW Crook. Predicting antimicrobial susceptibilities for escherichia coli and klebsiella pneumoniae isolates using whole genomic sequence data. *Journal of Antimicrobial Chemotherapy*, 68(10):2234–2244, 2013.
- [4] Marcus Nguyen, Thomas Brettin, S Wesley Long, James M Musser, Randall J Olsen, Robert Olson, Maulik Shukla, Rick L Stevens, Fangfang Xia, Hyunseung Yoo, et al. Developing an in silico minimum inhibitory concentration panel test for klebsiella pneumoniae. *Scientific reports*, 8(1):421, 2018.
- [5] Katharine M Jenike, Lucía Campos-Domínguez, Marilou Boddé, José Cerca, Christina N Hodson, Michael C Schatz, and Kamil S Jaron. K-mer approaches for biodiversity genomics. *Genome research*, 35(2):219, 2025.
- [6] F. Camacho, R. Leekitcharoenphon, and F. M. Aarestrup. Protein k-mer composition as a feature for antimicrobial resistance prediction. *Frontiers in Microbiology*, 11:1048, 2020.
- [7] Robert D Olson, Rida Assaf, Thomas Brettin, Neal Conrad, Clark Cucinell, James J Davis, Donald M Dempsey, Allan Dickerman, Emily M Dietrich, Ronald W Kenyon, et al. Introducing the bacterial and viral bioinformatics resource center (bv-brc): a resource combining patric, ird and vipr. *Nucleic acids research*, 51(D1):D678–D689, 2023.
- [8] Anna Fàbrega, Sergi Madurga, Ernest Giralt, and Jordi Vila. Mechanism of action of and resistance to quinolones. *Microbial biotechnology*, 2(1):40–61, 2009.
- [9] Michael Feldgarden, Vyacheslav Brover, Narjol Gonzalez-Escalona, Jonathan G Frye, Julie Haendiges, Daniel H Haft, Maria Hoffmann, James B Pettengill, Arjun B Prasad, Glenn E Tillman, et al. Amrfinderplus and the reference gene catalog facilitate examination of the genomic links among antimicrobial resistance, stress response, and virulence. *Scientific reports*, 11(1):12728, 2021.
- [10] Doug Hyatt, Gwo-Liang Chen, Philip F LoCascio, Miriam L Land, Frank W Larimer, and Loren J Hauser. Prodigal: prokaryotic gene recognition and translation initiation site identification. *BMC bioinformatics*, 11(1):119, 2010.
- [11] Isabelle Guyon and André Elisseeff. An introduction to variable and feature selection. *Journal of machine learning research*, 3(Mar):1157–1182, 2003.
- [12] Takuya Akiba, Shotaro Sano, Toshihiko Yanase, Takeru Ohta, and Masanori Koyama. Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining*, pages 2623–2631, 2019.
- [13] Scott M Lundberg and Su-In Lee. A unified approach to interpreting model predictions. *Advances in neural information processing systems*, 30, 2017.